

Journées Régionales Drones et Véhicules Autonomes (JRDVA)

24 & 25 avril 2025

Dunkerque, site de l'École de commerce ISCID-CO



Filtre particulaire ensembliste par intervalles pour le suivi de cibles

Mohamed Fnadi^{1,*}, Régis Lherbier¹

¹LISIC – UR4491, Université du Littoral Côte d'Opale, France

*mohamed.fnadi@univ-littoral.fr

Contexte

Dans de nombreux systèmes autonomes (drones, véhicules intelligents), le suivi d'une cible repose sur des mesures bruitées, rendant l'estimation complexe à cause des incertitudes liées aux modèles et aux capteurs. Deux approches principales se distinguent dans la littérature :

- **Bayésiennes** : Adaptées aux systèmes non linéaires/non gaussiens (ex. filtre à particules), mais nécessitent des hypothèses fortes (modèle et bruit connus).
- **Ensemblistes** : Garantissent que l'état réel est dans une boîte d'intervalles, offrant robustesse mais parfois trop conservatrices, donc moins précises.

Notre contribution : un **Filtre à Particules par Intervalles (IPF)**, une méthode hybride qui combine les deux approches pour exploiter leurs avantages respectifs — la précision des méthodes probabilistes et la robustesse des méthodes ensemblistes.

Filtrage particulaire ensembliste (IPF)


Le Filtre IPF est une méthode hybride qui combine les forces des approches probabilistes et ensemblistes pour une estimation d'état plus robuste et fiable.

Principe

Chaque particule représente un état de la cible **sous forme de boîte d'intervalle**. La propagation se fait via des **fonctions d'inclusion dynamique**. La mise à jour des poids utilise un algorithme de **propagation de contraintes**, basé sur les mesures, l'observation et la contraction des intervalles.

Algorithme du filtre IPF

Le filtre IPF s'articule autour de plusieurs étapes successives, permettant de prédire, corriger et resserrer les estimations de l'état de la cible à partir de mesures incertaines. Ci-dessous, un aperçu des étapes clés du processus :

1 Initialisation $\left\{ \left[\mathbf{x}_0^{(\eta)} \right], \omega_0^{(\eta)} = \frac{1}{N_p} \right\}_{\eta=1}^{N_p}$  <i>N_p boîtes particules initiales</i>	3 Contraction des boîtes de particules $\left\{ \left[\mathbf{y}_{k+1}^{(\eta)} \right] = [\mathbf{g}] \left(\left[\mathbf{x}_{k+1}^{(\eta)} \right] \right) \right\}_{\eta=1}^{N_p}$ $\left\{ \left[\tilde{\mathbf{y}}_{k+1}^{(\eta)} \right] = \left[\mathbf{y}_{k+1}^{(\eta)} \right] \cap \left[\mathbf{y}_{k+1} \right] - \left[\mathbf{v}_{k+1}^{(\eta)} \right] \right\}_{\eta=1}^{N_p}$ $\left\{ \left[\mathbf{v}_{k+1}^{(\eta)} \right] = \left[\mathbf{v}_{k+1} \right] \cap \left[\mathbf{y}_{k+1} \right] - \left[\mathbf{y}_{k+1}^{(\eta)} \right] \right\}_{\eta=1}^{N_p}$ $\left\{ \left[\mathbf{y}_{k+1}^{(\eta)} \right] = \left[\mathbf{y}_{k+1}^{(\eta)} \right] \cap \left[\mathbf{a} \right] + \left[\mathbf{v}_{k+1}^{(\eta)} \right] \right\}_{\eta=1}^{N_p}$ $\left\{ \left[\tilde{\mathbf{x}}_{k+1}^{(\eta)} \right] = \left[\mathbf{x}_{k+1}^{(\eta)} \right] \cap \mathbf{g}^{-1} \left(\left[\mathbf{y}_{k+1}^{(\eta)} \right] \right) \right\}_{\eta=1}^{N_p}$ <i>Données capteurs $\left[\mathbf{y}_{k+1} \right]$ + inclusion par intervalles</i>
2 Prédiction $\left\{ \left[\mathbf{x}_{k+1}^{(\eta)} \right] = [\mathbf{f}] \left(\left[\mathbf{x}_k^{(\eta)} \right], \left[\mathbf{u}_k \right], \left[\mathbf{w}_k^{(\eta)} \right] \right) \right\}_{\eta=1}^{N_p}$  <i>Propagation avec incertitude système</i>	5 Estimation et Rééchantillonnage $\hat{\mathbf{x}}_{k+1} = \sum_{\eta=1}^{N_p} \omega_{k+1}^{(\eta)} \text{mid} \left(\left[\mathbf{x}_{k+1}^{(\eta)} \right] \right) = \sum_{\eta=1}^{N_p} \omega_{k+1}^{(\eta)} \mathbf{c}_{k+1}^{(\eta)}$ <i>Pondération par les centres des boîtes</i> $N_{\text{eff}} = \frac{1}{\sum_{\eta=1}^{N_p} \left(\omega_{k+1}^{(\eta)} \right)^2}$ <i>Si $N_{\text{eff}} < \text{seuil}$: régénération</i>
4 Correction $\left\{ \text{Vrai} \left[\mathbf{x}_{k+1}^{(\eta)} \right] = \prod_{j=1}^{n_x} \frac{\left\ \left[\tilde{\mathbf{x}}_{k+1}^{(\eta)}(j) \right] \right\ }{\left\ \left[\mathbf{x}_{k+1}^{(\eta)}(j) \right] \right\ } \right\}_{\eta=1}^{N_p}$ <i>Vraisemblance</i> $\left\{ \omega_{k+1}^{(\eta)} = \text{Vrai} \left[\mathbf{x}_{k+1}^{(\eta)} \right] \times \omega_k^{(\eta)} \right\}_{\eta=1}^{N_p}$ <i>Mise à jour des poids</i>	

Conclusion & Perspectives

Le filtre IPF combine la précision des approches probabilistes à la fiabilité des méthodes ensemblistes. Les résultats montrent un compromis efficace entre performance et coût, idéal pour le suivi de cibles dans des systèmes dynamiques incertains.

Perspectives :

- Simulations avancées : LiDAR mobile, environnement dynamique, suivi multi-cibles.
- Campagnes expérimentales : données réelles avec LiDAR Ouster OS-128 en milieu marin

Références

1. L. Jaulin, M. Kieffer, O. Didrit, and E. Walter. Interval analysis. In: Applied interval analysis, pp. 11-43. Springer, London, 2001.
2. F. Abdallah, A. Gning, and P. Bonnifait. Box particle filtering for nonlinear state estimation using interval analysis. Automatica, 44(3), pp. 807-815, 2008.
3. A. Gning, L. Mihaylova, F. Abdallah, and B. Ristic. Particle Filtering Combined with Interval Methods for Tracking Applications. Integrated Tracking, Classification, and Sensor Management, 43-74, 2013.

Formulation du problème

L'objectif est d'estimer, avec précision et garanties, l'état d'une cible mobile (comme sa position ou sa vitesse) à chaque instant, en s'appuyant à la fois sur son modèle de dynamique et sur des mesures bruitées issues de capteurs (LiDAR, GNSS, etc.). Le comportement de la cible est décrit par deux équations fondamentales :

- **Dynamique de la cible** : $\mathbf{x}_{k+1} = \mathbf{f}(\mathbf{x}_k, \mathbf{u}_k, \mathbf{w}_k)$

où $\mathbf{f}$ est une fonction non linéaire représentant la transition d'état, $\mathbf{u}_k$ une commande, et $\mathbf{w}_k$ un bruit/processus incertain (modélisé par un intervalle).

- **Modèle d'observation** : $\mathbf{y}_k = \mathbf{g}(\mathbf{x}_k) + \mathbf{v}_k$

où $\mathbf{g}$ est la fonction de mesure, et $\mathbf{v}_k$ est le bruit de capteur (également modélisé comme un intervalle).

L'enjeu est d'estimer $\mathbf{x}_k$ malgré :

- des incertitudes sur $\mathbf{f}$, $\mathbf{g}$, $\mathbf{w}_k$, $\mathbf{v}_k$;
- la nature non linéaire du système ;
- des données capteurs incomplètes ou bruitées.

Application IPF : suivi d'un ASV via LiDAR

L'application d'IPF au suivi d'un ASV a été simulée sous INTLAB (INTerval LABoratory), en prenant en compte les incertitudes liées aux modèles dynamiques et aux mesures. Les résultats présentés sont obtenus sous les hypothèses suivantes :

Hypothèses :

1. Le véhicule évolue dans un plan XY.
2. Le capteur LiDAR est statique avec une position connue dans le référentiel inertiel et positionné de manière connue.
3. Les mesures sont bruitées et soumises à des incertitudes bornées.
4. Le modèle dynamique et d'observation de la cible est non linéaire et incertain




Figure 1: Principe du filtre IPF pour le suivi d'ASV

Les performances de l'IPF sont comparées à celles du filtre à particules classique (PF) pour différents nombres de particules, comme illustré en Fig. 2 et Tab. 1.




Figure 2: Comparaison des performances de suivi d'ASV entre filtre particulaire classique (PF, Np=1000), ensembliste (IPF, Np=200) [Gauche] Trajectoires estimées [Droite] Erreurs de position et Temps de calcul

	Np	Temps moyen (s)	RMSE position (m)	RMSE angle (°)
IPF	100	0.0265	0.1943	2.9420
IPF	200	0.0633	0.1656	2.1821
PF	200	0.0894	0.2319	2.8035
PF	1000	0.1392	0.1583	2.2574

Tableau 1: Comparaison des performances IPF vs PF

- À nombre de particules comparable, **IPF offre une meilleure précision en position que PF, tout en étant plus rapide.**
- L'IPF reste compétitif, **même avec un faible nombre de particules**, ce qui le rend adapté aux systèmes incertains.

Filtre particulaire ensembliste par intervalles pour le suivi de cibles

Mohamed Fnadi^{1,*}, Régis Lherbier¹

¹LISIC – UR4491, Université du Littoral Côte d'Opale, France;

* mohamed.fnadi@univ-littoral.fr

Le filtre particulaire, méthode de Monte Carlo séquentielle, représente une approche fondamentale pour l'estimation d'état dans les systèmes autonomes. Son efficacité dépend principalement de deux paramètres critiques: le nombre de particules utilisées et la fonction de densité qui régit l'adaptation de leurs poids à chaque itération. Nous proposons une extension ensembliste du filtre particulaire classique, fondée sur une formalisation par intervalles à erreurs bornées.

Contrairement aux approches classiques utilisant des particules ponctuelles, notre méthode repose sur une représentation ensembliste par intervalles. L'algorithme s'articule autour de quatre phases clés. La phase de prédiction propage chaque particule, modélisée sous forme de boîtes d'intervalles, à travers les fonctions d'inclusion du modèle dynamique, intégrant ainsi les incertitudes du système et de la commande. En phase de correction, les intervalles sont affinés par intersection avec les mesures des capteurs ajustées dans des intervalles, en prenant en compte leurs bruits. Les poids des particules sont ajustés dynamiquement selon le recouvrement de chaque boîte avec le modèle de mesure. Une contraction dynamique resserre les bornes des intervalles pour éviter la surestimation des incertitudes, en exploitant la technique de propagation des contraintes. Enfin, un rééchantillonnage adaptatif sélectionne les particules les plus probables en fonction de leurs poids et vérifie leur diversité via un seuil de variance effective. L'état estimé est obtenu par une moyenne pondérée des centres des particules.

Notre méthode a été appliquée au suivi de cibles en environnements marins incertains, notamment pour des véhicules autonomes de surface (ASV), en utilisant la bibliothèque INTLAB¹ pour le calcul par intervalles. Le système intègre un LiDAR fixe (dans le référentiel global) fournissant à chaque instant deux mesures télémétriques intervalaires bruitées : la distance et l'orientation de l'ASV par rapport au repère LiDAR. L'analyse comparative (Figure 2) entre notre approche ensembliste (IPF avec $N = 200$ particules) et un filtre à particules classique (PF avec $N = 1000$ particules) met en évidence deux atouts majeurs: (i) une réduction de 70 % du nombre de particules nécessaires, tout en garantissant une estimation certifiée et précise à partir des observations LiDAR ; (ii) un temps de calcul considérablement réduit, tout en maintenant (voire améliorant) la précision des estimations. Dans le cadre de nos travaux futurs, nous approfondirons nos simulations sur des scénarios plus complexes, tels que l'utilisation d'un LiDAR mobile embarqué sur une plateforme pour le suivi d'objets marins, avec une validation expérimentale sur des données réelles.




Figure 1: Comparaison des performances de suivi d'ASV entre filtre particulaire classique (PF, $N_p=1000$), ensembliste (IPF, $N_p=200$) [Gauche] Trajectoires estimées [Droite] Erreurs de position et Temps de calcul

Références:

- [1] L. Jaulin, M. Kieffer, O. Didrit, and E. Walter. Interval analysis. In: Applied interval analysis, pp. 11-43. Springer, London, 2001.
- [2] F. Abdallah, A. Gning, and P. Bonnifait. Box particle filtering for nonlinear state estimation using interval analysis. Automatica, 44(3), pp. 807-815, 2008.
- [3] A. Gning, L. Mihaylova, F. Abdallah, and B. Ristic. Particle Filtering Combined with Interval Methods for Tracking Applications. In-Integrated Tracking, Classification, and Sensor Management, pp. 43-74, 2013.
- [4] N. Merlinge, K. Dahia, H.J. Piet-Lahanier, Brusey, and N. Horri. A box regularized particle filter for state estimation with severely ambiguous and non-linear measurements. Automatica, 104, pp.102-110, 2019.

¹ <https://www.tuhh.de/ti3/rump/intlab/>